UNIDAD Nº 1

ESTADÍSTICA

1. ¿Qué es la estadística? ¿Por qué estudiar estadística?

La estadística es el estudio de los fenómenos aleatorios. En este sentido la ciencia estadística tiene, un alcance ilimitado de aplicaciones en un espectro muy amplio de disciplinas que van desde las ciencias y la ingenierita hasta las leyes y la medicina. Es decir esta ciencia trata la teoría y aplicación de métodos para coleccionar datos, analizarlos y extraer conclusiones a partir de ellos.

A la estadística para su estudio se la divide en dos partes:

- ✓ *Estadística descriptiva* está relacionada con la recolección de datos, organización, representación, análisis y descripción de los mismos. Esta es muy valiosa en casos donde se encuentra disponible la población completa y no existe incertidumbre, o cuando se tienen muestras aleatorias grandes.
- ✓ *Estadística inferencial o inductiva* el aspecto más importante de la estadística es la obtención de conclusiones basadas en los datos experimentales. Este proceso se conoce como *inferencia estadística.* El objetivo de la estadística inferencial es obtener información de la población a través del análisis de una muestra aleatoria y representativa de la misma.

Esta materia está destinada al estudio de la estadística descriptiva.

1.1. Población y muestra estadística

Para comprender la naturaleza de la inferencia estadística, es necesario entender las nociones de población y muestra.

- ✓ *Población* es la colección de toda la posible información que caracteriza a un fenómeno, en este sentido una población estadística es cualquier colección de datos los cuales pueden ser finitos o infinitos.
- ✓ *Muestra* es un subconjunto representativo seleccionado de una población. Una buena muestra es aquella que refleja las características esenciales de la población de la cual se obtuvo.

Ejemplo: se desea realizar un estudio estadístico para determinar la cantidad de personas de Mendoza realizan turismo interno, solo se entrevista a 15 personas de cada uno de los departamentos de Mendoza.

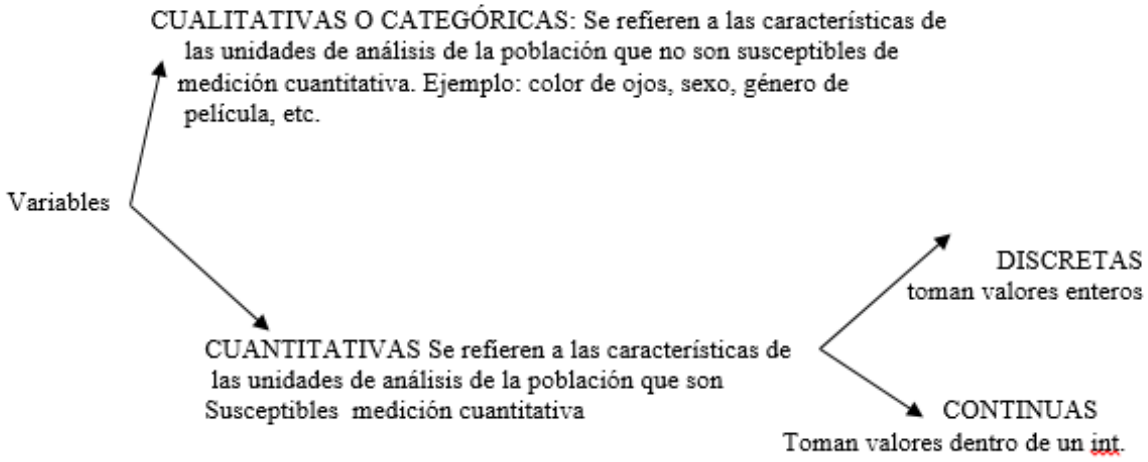
Este es un ejemplo donde para realizar el trabajo estadístico no se trabaja con toda la población, debido a que resulta imposible entrevistar a todos los individuos de la población, en este caso podemos decir que la población está formada por los habitantes de Mendoza, la muestra está conformada por 15 personas de cada uno de los departamentos de Mendoza, es decir 270 personas.

El estudio se realiza para poder determinar la cantidad de habitantes que realizan turismo interno, este dato en estadística se denomina variable estadística de estudio, veamos a continuación su definición y como se clasifican.

1.2. Variables estadísticas

Las variables estadísticas se definen como las características que sintetizan o abrevian, conceptualmente, lo que se desea conocer acerca de las unidades de análisis.

Básicamente existen dos tipos de variables:



Ejemplo determinar en casa caso población, muestra variable y tipo de variable estadística

a) Se desea realizar un trabajo de investigación estadística para averiguar el promedio de dinero que los jubilados de Mendoza destinan en turismo, solo se entrevista a jubilados de Godoy Cruz, San Rafael y Las Heras.

Población: Jubilados de Mendoza

Muestra: Jubilados de los departamentos Godoy Cruz, San Rafael y Las Heras.

Variable: promedio de dinero que destinan a turismo.

Tipo de variable: Cuantitativa continua.

b) Se realiza un trabajo estadístico para averiguar el color preferido por los estudiantes de 5to año de la provincia de Mendoza, solamente se entrevistan a los estudiantes de los colegios Belgrano, Pable Vázquez e Ingeniero Gabriel del Mazo

Población: Estudiantes de 5to año de Mendoza.

Muestra: Estudiantes de 5to año de los colegios Belgrano, Pable Vázquez y Ingeniero Gabriel del Mazo.

Variable: color preferido.

Tipo de variable: cualitativa.

2. Etapas de una investigación estadística

Las etapas que recorre un investigador en el intento de responder a preguntas importantes son las siguientes:

1. ***Formulación o definición del problema***
2. ***Diseño del experimento***

   Una vez que el problema ha sido claramente formulado el investigador debe decidir entre estudiar a la población en su totalidad u observar solo una parte de ella (muestra). Se debe tener especial cuidado al diseñar la muestra en caso contrario no se podrá llegar a ninguna conclusión válida. Existen diferentes tipos de diseño muestral los cuales dependen del tipo de población y el propósito del análisis.
3. ***Recolección de datos***

   De acuerdo con la localización de la información, los datos estadísticos pueden ser internos o externos, estos últimos son generalmente obtenidos de dos maneras: de datos publicados o a través de encuestas.
4. ***Organización, tabulación, representación y descripción de los resultados***

   El primer paso para organizar un grupo de datos es corregir cada uno de ellos, luego es decidir las clasificaciones adecuadas para incluir todos los elementos y finalmente tabularlos. Existen tres formas de presentar un conjunto de datos recopilados mediante enunciados, tablas estadísticas y gráficos estadísticos, para analizarlos se calculan las medidas de tendencia central y desviación.
5. ***Generalización o inferencia final***

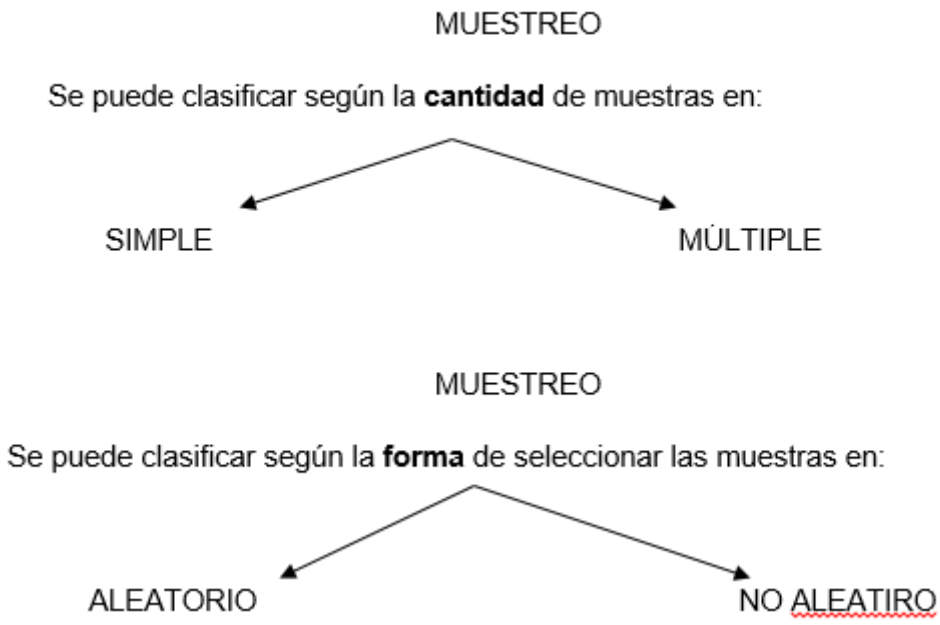
   En este paso se trata de dar respuesta al problema formulado mediante el análisis y la interpretación de las medidas de tendencia central y desviación, este procedimiento se llama generalización cuando se trabaja con la totalidad de la

población (estadística descriptiva) o inferencia cuando se trabaja con una muestra (estadística inferencial).

3. Teoría de muestreo

El objetivo de las técnicas de muestreo es asegurar que la muestra seleccionada cumpla con las condiciones de representatividad, aleatoriedad e independencia.

- ✓ ***Representatividad*** una muestra debe revelar las características de la población de la cual proviene lo más aproximadamente posible. Por lo tanto no sirve cualquier proporción de la misma. Para esto se debe lograr que el tanto por ciento de individuos de la muestra que poseen una propiedad determinada ha de ser mismo que el tanto porciento de individuos con esta propiedad en la población
- ✓ ***Aleatoriedad*** cada elemento de la población debe tener la misma posibilidad de ser elegido. Solo si satisface este requisito los métodos estadísticos serán razonables.
- ✓ ***Independencia*** la probabilidad de que cualquier miembro de la población aparezca en la muestra no depende de la aparición de los otros miembros de la población en la muestra.



3.1. Muestreo aleatorio simple

- ✓ Cada muestra posible del mismo tiene igual probabilidad de ser seleccionada de la población.

- ✓ Cada elemento de la población debe tener igual probabilidad de ser seleccionado.
- ✓ Un método para obtener una muestra aleatoria simple es elegir al azar el número de elementos deseados para la muestra.

3.2. Muestreo sistemático

- ✓ Los elementos son seleccionados de una manera ordenada.
- ✓ El número de elementos en la población es dividido por el número deseado en la muestra. Este valor se llama ***razón de muestreo***

$$r = \frac{N}{n}$$

- ✓ El primer elemento de la muestra es seleccionado al azar entre los primeros "p" elementos, si el primer elemento es el aº en la población, el segundo será aº + r, el tercero será (aº + r) + r y así sucesivamente

Ejemplo: *de una población de 100 individuos se desea obtener una muestra de 20 individuos, la razón de muestreo es:*

$$r = \frac{100}{20} = 5$$

Se elije al azar entre los primeros cinco elementos, por ejemplo, el 3º, entonces el segundo seleccionado será el 8º (3+5), el tercero será 13º (8+5), y así sucesivamente.

3.3. Muestreo aleatorio estratificado

- ✓ Se divide la población en grupos llamados ***estratos***, que son más homogéneos que la población como un todo.
- ✓ Los elementos de la muestra son, entonces, seleccionados al azar o por un método sistemático de cada estrato.
- ✓ El número de elementos seleccionados de cada estrato puede ser proporcional o no al tamaño del estrato en relación con la población.

3.4. Muestreo de conglomerados

- ✓ Se divide a la población en grupos que son convenientemente para le muestreo.
- ✓ Se selecciona una cantidad de grupos al azar o por un método sistemático.
- ✓ Finalmente se toman todos los elementos o parte de ellos (al azar o por un método sistemático) de los grupos seleccionados para obtener una muestra

- ✓ Una muestra de conglomerados, usualmente produce un mayor error muestral que una muestra simple del mismo tamaño.

La teoría de muestreo no será un tema a evaluar en forma práctica en esta asignatura, debido a que trabajaremos con una estadística descriptiva es decir con el total de individuos de una pobalcion.

4. Organización y representación de datos

Una vez que se han recolectado todas las unidades de análisis, es necesario organizar los datos mediante una tabla que ofrezca una visión numérica sintética y global de la variable, con le objetivo de analizarlos y extraer conclusiones.

La presentación de la información obtenida se puede realizar mediante varias formas:

- ✓ Textual (en forma de informe)
- ✓ Tablas de distribución de frecuencias
- ✓ Gráficos

4.1. Tabla de distribución de frecuencias

La tabla de distribución de frecuencias tiene como finalidad presentar en forma ordenada los valores que toma la variable, en tal forma que permitan al lector tener una visión conjunta de la información estadística. Cuando se hace un relevamiento de datos, puede pasar que algunos de ellos se repitan; se llama **frecuencia absoluta** a la cantidad de veces que se repite un determinado valor de la variable. La **frecuencia relativa** es la fracción del total que representa cada valor de la variable. Si se multiplica por 100% la frecuencia relativa expresada en decimal, se obtiene el porcentaje de la variable que se llama **frecuencia relativa porcentual.**

Ejemplos:

1) Para una investigación sobre la descendencia, Conrad (1937- 1940) reunió a 07 adultos con ataques comprobados de epilepsia, a fin de analizar las enfermedades halladas en sus hijos.

La variable en estudio es por lo tanto: "Hallazgos anormales en los hijos de epilépticos"

Tabla de distribución de frecuencias

Enfermedades que manifiestan los hijos de epilépticos	*F. absoluta (fa)*	*F. relativa (fr)*	*F. relativa porcentual (fr%)*	*F. acumulada (Fa)*
Epilepsia	*70*	*70/507 = 0,1381*	*13,81%*	*70*
Debilidad mental	*200*	*200/507 = 0,3945*	*39,45 %*	*270*
Psicosis	*45*	*45/507 = 0, 0888*	*8, 88 %*	*315*
Personalidades anormales	*93*	*93/507 = 0,1834*	*18,34 %*	*408*
Estados morfológicos anormales	*50*	*50/507 = 0,0986*	*9,86 %*	*458*
Estados funcionales anormales	*29*	*29/507 = 0,0572*	*5, 72 %*	*487*
Enfermedades neurológicas	*20*	*20/507 = 0, 0394*	*3, 94 %*	*507*
total	*507*	*507/507 = 1*	*100%*	----------

2) *Estas son las temperaturas máximas registradas en Tandil del 25 de Junio al 4 de Julio del 2010: 8º C, 9º C, 8º C, 3º C, 11º C, 12º C, 10º C, 8ºC, 10º C, 11º C. Indicar cual es la variable y construir una tabla de distribución de frecuencias.*

La variable en estudio es: temperaturas máximas registradas en Tandil

Tabla de distribución de frecuencias

Temperaturas	*F. absoluta (fa)*	*F. relativa (fr)*	*F. relativa porcentual (fr%)*	*F. acumulada (Fa)*
3º C	1	1/10 = 0,1	10 %	1
8º C	3	3/10 = 0,3	30 %	4
9º C	1	1/10 = 0,1	10 %	5
10º C	2	2/10 = 0,2	20 %	7
11º C	2	2/10 = 0,2	20 %	9
12º C	1	1/10 = 0,1	10 %	10
Total	10	10/10 = 1	100 %	----------

3) *Los siguientes datos representan la cantidad de miembros que integran cada una de las familias que aspiran a obtener un préstamo hipotecario: 2, 3, 3, 4, 4, 4, 4, 4, 5, 5, 6, 6, 6, 6, 7, 7, 8, 9, 9, 12. Construir una tabla de distribución de frecuencias con intervalos.*

Para estudiar un hecho en el que la amplitud de la población es grande, o donde la variable es continua, los datos se agrupan en intervalos de clase. Se llama ***intervalo de clase*** *a cada uno de los intervalos de números reales en que se agrupan los valores de la variable. Estos intervalos pueden tener una amplitud constante o variable.*

El principal problema es determinar el número apropiado de intervalos el cual dependerá de la precisión de las medidas que se pretende alcanzar, finalidad del estudio, grado de variabilidad de los datos, etc, aunque no existe una regla precisa para esta decisión, generalmente se trata de no tener demasiados o muy pocos intervalos, lo cual tiende a producir irregularidades en las frecuencias de los mismos. En la práctica se trata de no tener una distribución de frecuencias con menos de cinco o más de quince intervalos.

Pasos parar formar intervalos:

1º Determinar el rango que es la diferencia entre el valor máximo y mínimo. $R = X_{max} - X_{min}$

$X_{max} = 12 \quad X_{min} = 2 \quad R = 12 - 2 = 10$

2º Calcular el número de intervalos mediante la regla Sturges

$M = 1 + 3{,}3 \cdot \log n$

$M = 1 + 3{,}3 \cdot \log 20 = 5{,}29 \cong 5$

3º Calcular la amplitud de cada intervalo mediante la siguiente fórmula $A = \frac{R}{M}$

$A = 10/5 = 2$

4º Armar los intervalos

Para el primer intervalo se toma como límite inferior el valor mínimo de la variable y luego se le suma el valor de la amplitud del intervalo para hallar el límite superior, en nuestro ejemplo quedaría:

> *[2 –4) 2 y 4 son los límites del intervalo de amplitud A = 4 – 2 = 2***,** *luego se procede a obtener los límites del intervalo siguiente utilizando como límite inferior al límite superior del intervalo anterior y así sucesivamente. Para calcular la marca de clase*

o punto del intervalo (Xim) se realiza el promedio aritmético de los límites del intervalo: $Xim = \frac{2+4}{2} = 3$*. La frecuencia absoluta del intervalo se calcula determinado todos los valores comprendidos entre los extremos del intervalo sin considerar el límite superior del mismo*

Tabla de distribución de frecuencias

Intervalos	*Marca de clase Xim*	*F. absoluta (fa)*	*F. relativa (fr)*	*F. relativa porcentual (fr%)*	*F. acumulada (Fa)*
[2 –4)	*3*	*3*	*3/20 = 0,15*	*15 %*	*3*
[4– 6)	*5*	*7*	*7/20 = 0,35*	*35 %*	*10*
[6 – 8)	*7*	*6*	*6/20 = 0,3*	*30 %*	*16*
[8 – 10)	*9*	*3*	*3/20 = 0,15*	*15 %*	*19*
[10 - 12]	*11*	*1*	*1/20 = 0,05*	*5 %*	*20*
Total	----------	*20*	*20/20 = 1*	*100 %*	----------

4.2. Gráficos estadísticos

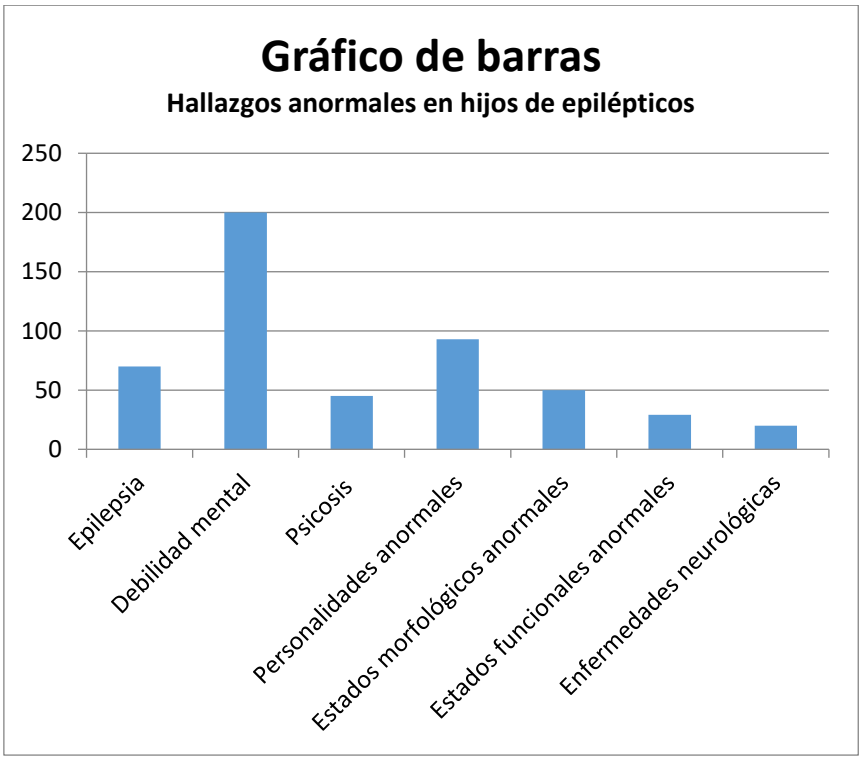
Los gráficos estadísticos proporcionan una representación de datos ilustrada, sus principales **ventajas** son: concisión, rapidez de percepción, vista conjunta de una situación y síntesis de datos, su principal **desventaja** es que desprecia detalles y resulta confuso cuando se pretende comparar varias distribuciones. Es necesario que los gráficos expliquen la fuente de donde fueron obtenidos los datos, además aclarar escalas, leyendas, notas y convenciones que ayuden a identificar las características presentadas, con el objetivo de evitar una lectura e interpretación errónea del mismo.

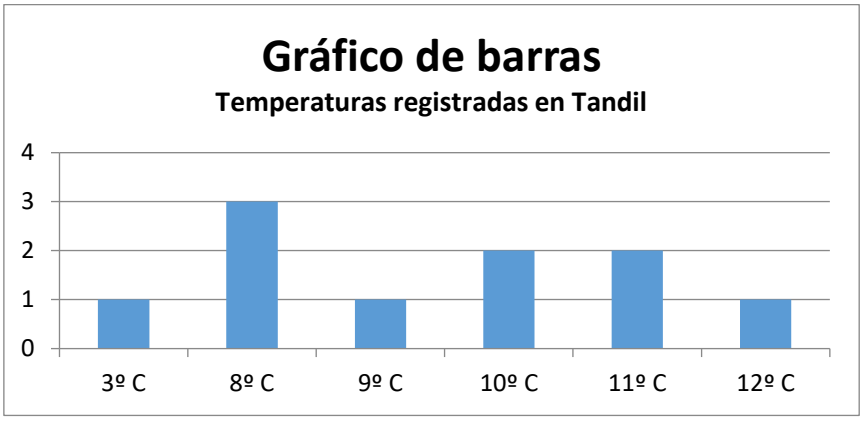
Existen numerosos tipos de gráficos pero solo vamos a estudiar aquellos que son considerados como los más usuales:

4.2.1. Gráfico de barras

Se utilizan para comparar datos entre si de variables discretas o cualitativas. En el eje horizontal se colocan los valores de la variable y en el eje vertical las frecuencias absolutas o relativas. Se construyen rectángulos de igual ancho, cuya altura corresponde al valor de la frecuencia absoluta o relativa, permitiendo realizar una rápida lectura de las diferencias de los valores registrados.

Ejemplo: *Construir el gráfico de barras correspondientes al análisis de los Hallazgos anormales en los hijos de epilépticos y a las temperaturas máximas registradas en Tandil, analizados anteriormente*





4.2.2. Gráfico circular o de sectores

Se utilizar generalmente cuando la variable de análisis es cualitativa, este gráfico muestra la distribución de los datos en relación con el total. Para ello se divide al círculo en sectores circulares que representan la parte de giro que corresponda al porcentaje de cada variable

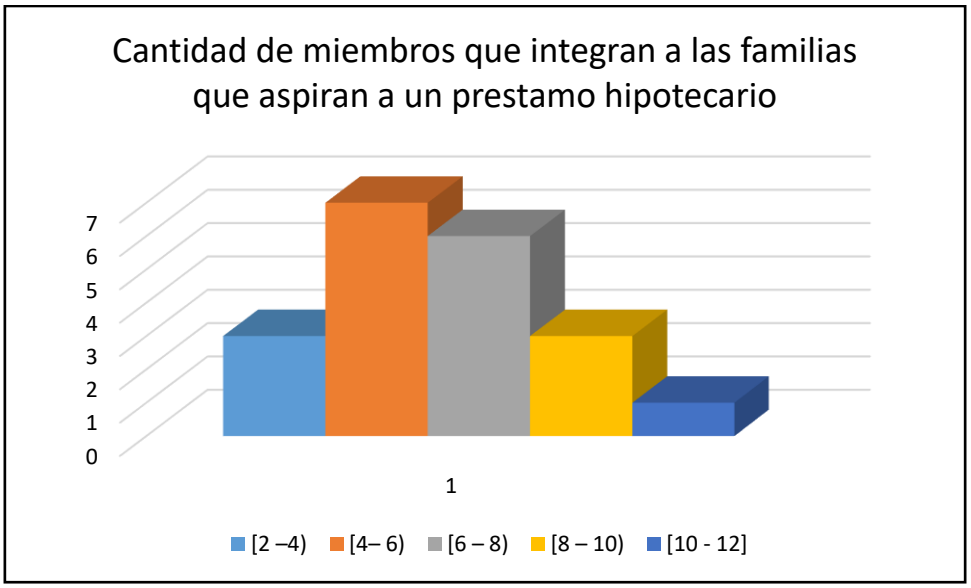
Ejemplo: *construir el gráfico de sectores correspondiente al análisis de los Hallazgos anormales en los hijos de epilépticos, analizados anteriormente*



4.2.3. Histograma

Este gráfico se utiliza para la representación de variables continuas, en el eje horizontal se colocan los intervalos y en el eje vertical las frecuencias absolutas o relativas. Se construyen rectángulos de igual base (amplitud del intervalo) y la altura esta dada por la frecuencia absoluta o relativa del intervalo

Ejemplo: *Realizar el histograma correspondiente a la cantidad de miembros que integran cada una de las familias que aspiran a obtener un préstamo hipotecario, analizado anteriormente*



MEDIDAS DE TENDENCIA CENTRAL

5. Medidas de tendencia central

Existen dos medidas de interés para analizar cualquier conjunto de datos: la localización y su variabilidad. La tendencia central de un conjunto de datos es la disposición de estos para agruparse ya sea alrededor del centro o de ciertos valores numéricos. La variabilidad de un conjunto de datos es la dispersión de las observaciones en el conjunto.

Existen principalmente tres medidas de tendencia central: Media, mediana y moda

5.1. Media aritmética

La media aritmética de las observaciones $x_1, x_2, \ldots, x_n$ es el promedio aritmético de éstas y se denota por:

$$\bar{X} = \sum_{i=1}^{n} \frac{x_i}{n}$$

x_i : dato i

n = número de datos en la muestra.

Ejemplo: *Calcular la media aritmética de los siguientes datos: 3, 5, 7, 8, 4, 2, 5, 1*

$$\bar{X} = \sum_{i=1}^{8} \frac{x_i}{n} = \frac{3+5+7+8+4+2+5+1}{8} = 4{,}375$$

Para datos agrupados

$$\bar{X} = \sum_{i=1}^{n} \frac{x_i . f_i}{n}$$

x_i : variable i

f_i : Frecuencia absoluta de la variable

n = número de datos en la muestra

Ejemplo: *Las siguientes son las notas en matemática de un grupo de 15 alumnos: 9 - 6- 3- 1- 5- 3- 6- 9- 7- 3- 1- 4- 4- 7- 6*

a) *Construir una tabla de distribución de frecuencias*
b) *Calcular e interpretar la media aritmética*

Solución

Notas	*F. absoluta (fa)*	*F. relativa (fr)*	*F. relativa porcentual (fr%)*	*F. acumulada (Fa)*
1	*2*	*2/15 = 0,133*	*13, 3%*	*2*

3	*3*	*3/ 15 = 0,2*	*20%*	*5*
4	*2*	*2/15 = 0,133*	*13, 3%*	*7*
5	*1*	*1/15 = 0,07*	*7%*	*8*
6	*3*	*3/ 15 = 0,2*	*20%*	*11*
7	*2*	*2/15 = 0,133*	*13, 3%*	*13*
9	*2*	*2/15 = 0,133*	*13, 3%*	*15*
total	*15*	*15/15 = 1*		----------

Media aritmética

$$\bar{X} = \sum_{i=1}^{15} \frac{x_i . f_i}{n} = \frac{1x2 + 3x3 + 4x2 + 5x1 + 6x3 + 7x2 + 9x2}{15} = 4{,}9$$

Interpretación: En promedio la nota en matemática de los alumnos es de 5

Para calcular la media aritmética se para datos agrupados en intervalos se aplica la siguiente fórmula:

$$\bar{X} = \sum_{i=1}^{n} \frac{x_{im} . f_i}{n}$$

X_{im}: marca de clase

f_i: frecuencia absoluta del intervalo

n = número de datos en la muestra

Ejemplo: *En una muestra de 20 monedas se registraron los siguientes pesos: 1 g 1,6 g 3 g 2,2 g 0,1g 3,1 g 2,8 g 2,4 g 1,7 g 3,5 g 4,9g 2,5 g 1,8 g 1,9 g 2g 3,4 g 4 g 4,1 g 2,3 g 2,7 g*

a) *Realizar una tabla de distribución de frecuencias con intervalos.*
b) *Calcular e interpretar la media aritmética*

Resolución:

Rango

$R = x_{max} - x_{min}$

$R = 5{,}1 - 0{,}1 = 5$

Número de intervalos

$M = 1 + 3{,}3 \cdot \log n$

$M = 1 + 3{,}3 \cdot \log 20 = 5{,}29$

$M \cong 5$

Amplitud de intervalo

$C = \frac{R}{M}$

$C = \frac{5}{5} = 1$

$C \cong 1$

Intervalos	*Marca de clase Xim*	*F. absoluta (fa)*	*F. relativa (fr)*	*F. relativa porcentual (fr%)*	*F. acumulada (Fa)*
[o – 1)	0,5	1	1/20 = 0,05	5%	1
[1 – 2)	1,5	5	5/20 = 0,25	25%	6
[2 – 3)	2,5	6	6/20 = 0,3	30%	12
[3 – 4)	3,5	4	4/20 = 0,2	20%	16
[4 – 5]	4,5	4	4/20 = 0,2	20%	20
Total	----------	20	20/20 = 1	100%	----------

a) *Media aritmética*

$$\bar{X} = \sum_{i=1}^{n} \frac{x_{im}.f_i}{n}$$

$$\bar{X} = \sum_{i=1}^{20} \frac{x_{im}.f_i}{n} = \frac{0{,}5x1 + 1{,}5x5 + 2{,}5x6 + 3{,}5x4 + 4{,}5x4}{20} = 2{,}75$$

Interpretación: En promedio el peso de las monedas es de 2,75 g

La media aritmética es una medida apropiada de tendencia central para muchos conjuntos de datos, sin embargo dado que cualquier observación en el conjunto se emplea para su cálculo, el valor de la media puede afectarse de manera desproporcionada por la existencia de algunos valores extremos.

Ejemplo: *las siguientes son las edades de los asistentes al cumpleaños de Ignacio: 2, 2, 2, 3, 3, 4, 4, 6, 35, 40. Calcular interpretar la media aritmética.*

$$\bar{X} = \sum_{i=1}^{8} \frac{x_i}{n} = \frac{2 + 2 + 2 + 3 + 3 + 4 + 4 + 6 + 35 + 40}{10} = 10{,}1$$

Interpretación: En promedio la edad de los asistentes al cumpleaños de Ignacio es de 10años.

Con este ejemplo se puede evidenciar que el valor de la media aritmética obtenido no es representativo del conjunto de datos

5.1.1. Propiedades de la media aritmética

- ✓ Punto de equilibrio de los datos de la muestra.

- ✓ Influenciable por los valores extremos.
- ✓ No se puede calcular en variables cualitativas y cuando la distribución de frecuencias tiene intervalos abiertos.
- ✓ La suma algebraica de las desviaciones de un conjunto de números respecto a su media aritmética es cero.

Ejemplo: *las desviaciones de los números 8, 3, 5, 12 y 10 respecto de su media aritmética 7,6 son:*

8 – 7,6 = 0,4 *3 – 7,6 = -4,6*

5 – 7,6 = -2,6 *12 – 7,6 = 4,4* *10 – 7,6 = 2,4*

La sumatoria de los desvíos es:

$$\sum \boldsymbol{d} = \mathbf{0,4} + (-\mathbf{4,6}) + (-\mathbf{2,6}) + \mathbf{4,4} + \mathbf{2,4} = \mathbf{0}$$

5.2. Mediana (Me)

La mediana es el valor central de un conjunto de datos ordenados. Esta divide a la distribución en dos partes iguales

Ejemplo:

1) *Calcular la mediana de los siguientes datos: 3, 4, 7, 7, 6, 5,9*

   3 4 5 [6] *7 7 9*

   Me = 6

2) *Calcular la mediana de los siguientes datos: 2, 4, 4, 5, 8,9,1,7*

   1 2 4 [4 5] *7 8 9*

   Me = $\frac{4+5}{2}$*=4,5*

   Cundo el número de datos es un número par la mediana es el promedio de los dos valores centrales

Para datos agrupados la mediana se calcula de la siguiente manera:

1) Determinar el orden de la mediana el cual se obtiene de dividiendo el número total de observaciones por 2.

   $^{o}Me = \frac{n}{2}$

2) Buscar el valor obtenido como orden de la mediana en la columna de frecuencia acumulada (Fa), si no esta, tomar el inmediato superior, al valor correspondiente de la variable se lo llama mediana.

Ejemplo: *Calcular e interpretar la mediana de las notas obtenidas por 15 alumnos en matemática, analizada anteriormente.*

Tabla de distribución de frecuencias

Notas	*F. absoluta (fa)*	*F. relativa (fr)*	*F. relativa porcentual (fr%)*	*F. acumulada (Fa)*
1	*2*	*2/15 = 0,133*	*13, 3%*	*2*
3	*3*	*3/ 15 = 0,2*	*20%*	*5*
4	*2*	*2/15 = 0,133*	*13, 3%*	*7*
5	*1*	*1/15 = 0,07*	*7%*	*8*
6	*3*	*3/ 15 = 0,2*	*20%*	*11*
7	*2*	*2/15 = 0,133*	*13, 3%*	*13*
9	*2*	*2/15 = 0,133*	*13, 3%*	*15*
total	*15*	*15/15 = 1*		----------

$^{o}Me = \frac{n}{2} = \frac{15}{2} = 7{,}5$

El primer valor de la variable cuya frecuencia acumulada surera dicho valor es 5, por lo tanto la mediana de las notas es 5.

Interpretación: 5 es la nota en matemática que divide a la distribución en dos partes iguales.

***Para calcular la mediana en datos agrupados en intervalos seguimos los siguientes pasos*:**

1) Calcular el orden de la mediana mediante la fórmula:
   $^{o}\ Me = \frac{n}{2}$
2) Buscar el valor obtenido como orden de la mediana en la columna de frecuencia acumulada (Fa), si no esta, tomar el inmediato superior y llamar al intervalo correspondiente intervalo mediano.
   Diremos que la mediana, pertenece a dicho intervalo, pero es necesaria una mayor precisión.
3) El valor de la mediana se obtiene con la siguiente fórmula:

$$\mathrm{Me} = \mathrm{L_i} + \left(\frac{{}^{o}\mathrm{Me} - \mathrm{F_{a-1}}}{\mathrm{fa}}\right).\mathrm{c}$$

Donde:

L_i: límite inferior del intervalo mediano.

F_{a-1}: Frecuencia acumulada correspondiente al intervalo anterior del intervalo mediano.

Fa: Frecuencia absoluta del intervalo mediano.

C: amplitud del intervalo mediano.

Ejemplo: *Calcular e interpretar la mediana del registro de los pesos de una muestra de 20 monedas, analizada anteriormente*

Tabla de distribución de frecuencias

Intervalos	*Marca de clase Xim*	*F. absoluta (fa)*	*F. relativa (fr)*	*F. relativa porcentual (fr%)*	*F. acumulada (Fa)*
[o – 1)	0,5	1	1/20 = 0,05	5%	1
[1 – 2)	1,5	5	5/20 = 0,25	25%	6
[2 – 3)	2,5	6	6/20 = 0,3	30%	12
[3 – 4)	3,5	4	4/20 = 0,2	20%	16
[4 – 5]	4,5	4	4/20 = 0,2	20%	20
Total	----------	20	20/20 = 1	100%	----------

1) *Calcular el orden de la mediana*

$$\frac{n}{2} = \frac{20}{2} = 10$$

2) *Determinar el intervalo mediano*

   Me ϵ [2 – 3)

3) *Calcular el valor de la mediana mediante la fórmula*

$$Me = L_i + \left(\frac{\frac{n}{2} - F_{a-1}}{fa}\right).c = 2 + \left(\frac{10-6}{6}\right).1 = 2{,}66$$

Interpretación: La mitad de los pesos de las monedas es menor o igual a 2,66 gramos y la otra mitad es mayor a 2,66 gramos

5.2.1. Propiedades de la mediana

- ✓ Se ubica en el medio de la distribución.
- ✓ No se ve afectada por los valores extremos.
- ✓ Se puede calcular en variables cualitativas que sean ordinales.

5.3. Moda

La moda de un conjunto de datos es el valor que más veces se repite, es decir es el valor de la variable que mayor frecuencia absoluta posee.

Ejemplo: *calcular la moda de los siguientes datos: 2, 2, 3, 3, 4, 4, 4, 5, 6*

Mo = 4

Ejemplo: *Calcular e interpretar la moda de las notas obtenidas por 15 alumnos en matemática, analizada anteriormente.*

Tabla de distribución de frecuencias

Notas	*F. absoluta (fa)*	*F. relativa (fr)*	*F. relativa porcentual (fr%)*	*F. acumulada (Fa)*
1	*2*	*2/15 = 0,133*	*13, 3%*	*2*
3	*3*	*3/ 15 = 0,2*	*20%*	*5*
4	*2*	*2/15 = 0,133*	*13, 3%*	*7*
5	*1*	*1/15 = 0,07*	*7%*	*8*
6	*3*	*3/ 15 = 0,2*	*20%*	*11*
7	*2*	*2/15 = 0,133*	*13, 3%*	*13*
9	*2*	*2/15 = 0,133*	*13, 3%*	*15*
total	*15*	*15/15 = 1*		----------

En esta distribución se puede observar que las notas 3 y 6 son las que mayor frecuencia absoluta poseen, por lo tanto:

Mo = 3 y 6 a esta distribución se la denomina bimodal.

Interpretación: 3 y 6 son las notas que más veces se registraron. La mayoría de los alumnos obtuvieron como nota en matemática un 3 o 6.

Para calcular la moda en datos agrupados en intervalos seguimos los siguientes pasos:

1) Determinar el intervalo modal, el cual es el intervalo de mayor frecuencia absoluta. La moda pertenece a dicho intervalo pero es necesario una mayor precisión.
2) El valor de la moda se obtiene mediante la fórmula:

$$Mo = L_i + \left(\frac{\Delta_1}{\Delta_1 + \Delta_2}\right).c$$

Donde:

L_i: límite inferior del intervalo mediano

Δ_1: Diferencia entre la frecuencia del intervalo modal y el intervalo anterior

Δ_2: Diferencia entre la frecuencia del intervalo modal y el intervalo siguiente.

C: amplitud del intervalo modal.

Ejemplo: *Calcular e interpretar la moda del registro de los pesos de una muestra de 20 monedas, analizada anteriormente*

Tabla de distribución de frecuencias

Intervalos	*Marca de clase Xim*	*F. absoluta (fa)*	*F. relativa (fr)*	*F. relativa porcentual (fr%)*	*F. acumulada (Fa)*
[o – 1)	0,5	1	1/20 = 0,05	5%	1
[1 – 2)	1,5	5	5/20 = 0,25	25%	6
[2 – 3)	2,5	6	6/20 = 0,3	30%	12
[3 – 4)	3,5	4	4/20 = 0,2	20%	16
[4 – 5]	4,5	4	4/20 = 0,2	20%	20
Total	----------	20	20/20 = 1	100%	----------

La mayor frecuencia absoluta es 6 que corresponde al intervalo [2 , 3) llamado intervalo modal.

Mo ϵ [2 , 3)

$$Mo = L_i + \left(\frac{\Delta_1}{\Delta_1 + \Delta_2}\right).c = 2 + \left(\frac{1}{1+2}\right).1 = 2{,}33$$

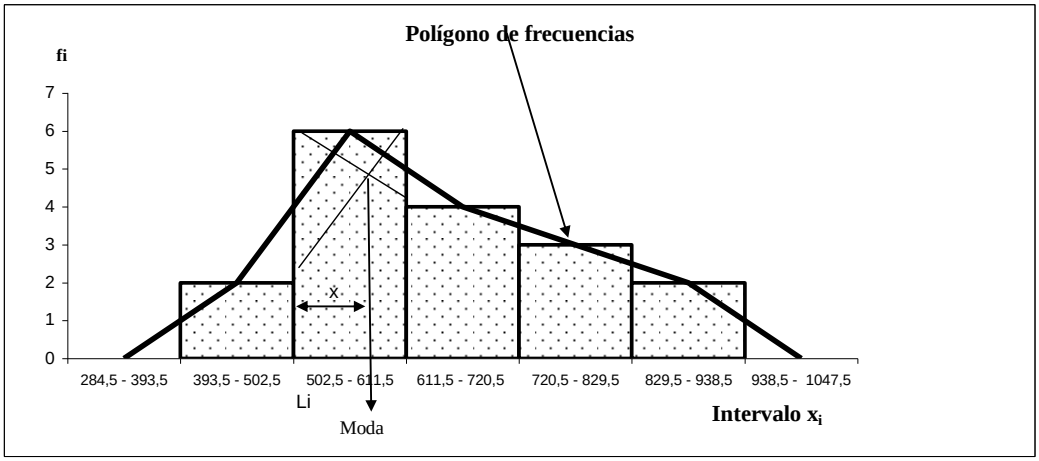
Siendo $\Delta_1 = 6 - 5 = 1$ $\Delta_2 = 6 - 4 = 2$

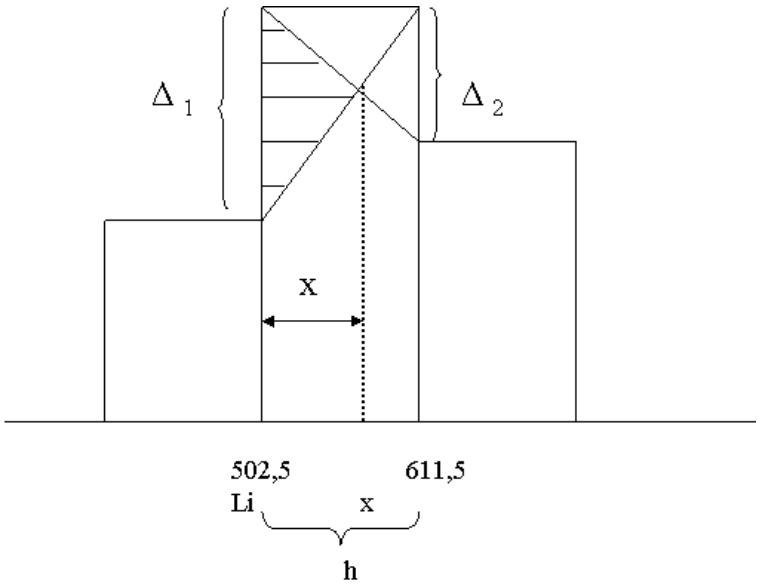
Interpretación: 2, 33 g fue el peso más registrado de las monedas.

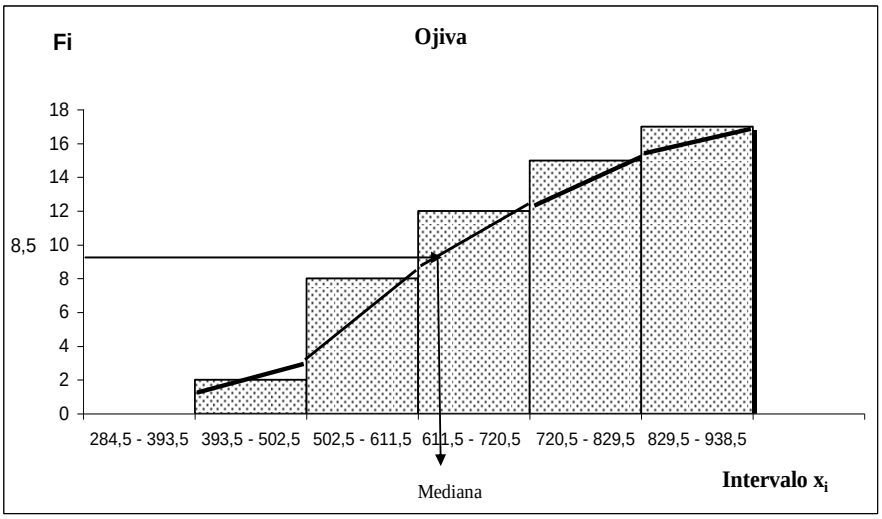
5.3.1. Propiedades de la moda:

- ✓ Es el valor de la variable que mayor frecuencia absoluta tiene.
- ✓ Se ubica en cualquier lugar.
- ✓ Una distribución puede poseer más de una moda.
- ✓ Puede calcularse en variables cualitativas.

Obtención de la mediana y moda gráficamente para intervalos






Fi
Ojiva
18
16
14
12
8,5 10
8
6
4
2
0
284,5 - 393,5
393,5 - 502,5
502,5 - 611,5
611,5 - 720,5
720,5 - 829,5
829,5 - 938,5
Mediana
Intervalo x_i

MEDIDAS DE DISPERSIÓN

6. Medidas de dispersión

Una medida de tendencia central proporciona información acerca de un conjunto de datos pero no proporciona ninguna idea de la variabilidad de las observaciones en dicho conjunto.

Para observar esto analicemos el siguiente ejemplo:

Para analizar el nivel académico de un seminario, se consultaron las notas de tres cursos A, B y C, de 25 alumnos cada uno. Los resultados obtenidos fueron los siguientes:

Curso A

Nota	*1*	*2*	*3*	*4*	*5*	*6*	*7*	*8*	*9*	*10*
fa	*1*	*2*	*2*	*1*	*2*	*7*	*3*	*3*	*2*	*2*

Curso B

Nota	*1*	*2*	*3*	*4*	*5*	*6*	*7*	*8*	*9*	*10*
fa	*4*	*1*	*1*	*1*	*2*	*6*	*1*	*2*	*2*	*5*

Curso C

Nota	*1*	*2*	*3*	*4*	*5*	*6*	*7*	*8*	*9*	*10*
fa	*1*	*1*	*1*	*1*	*3*	*11*	*1*	*3*	*2*	*1*

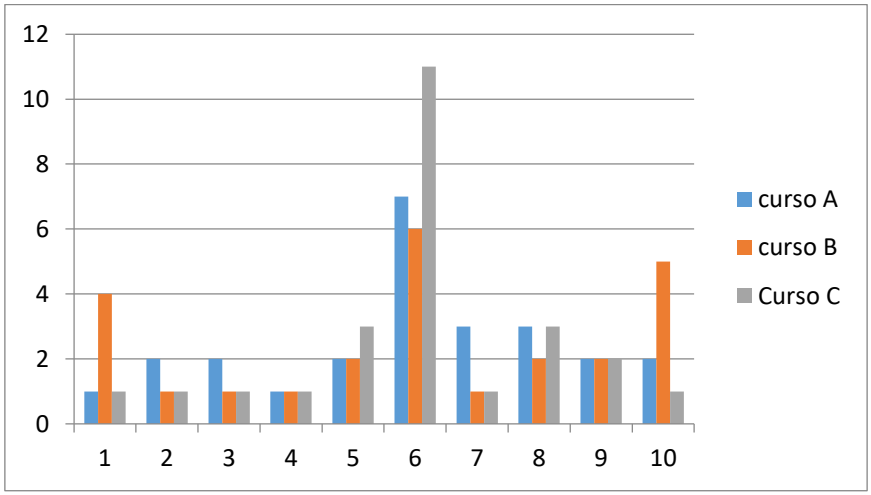
a) *Calcular media, median y moda de cada uno de los cursos*
b) *¿Para cuál de los tres cursos la media aritmética es más representativa de los datos?*

La siguiente tabla sintetiza los resultados obtenidos:

Curso	*Media ($\bar{X}$)*	*Mediana (Me)*	*Moda (Mo)*
A	*6*	*6*	*6*
B	*6*	*6*	*6*
C	*6*	*6*	*6*

Los tres cursos tienen las mismas medidas de tendencia central

Para analizar si en cada curso la media aritmética es representativa de las notas, realizamos en forma conjunta el gráfico de barras correspondiente a cada curso:



En el gráfico, podemos observar que los datos del curso A están bastante dispersos respecto de la media, o sea, poco concentrados alrededor de su promedio. El curso B tienen los datos menos distribuidos por todas las notas, y en las notas extremas 1 y 10 hay más datos que en los cursos A y C. Las notas del curso C son las que están más concentradas alrededor de su media aritmética. Aunque las tres distribuciones de frecuencias tienen las mismas medidas de tendencia, no son iguales. Por lo tanto, tenemos que encontrar una forma de determinar si la media aritmética es para cada curso, representativa de los datos o si no lo es. Es decir, para cada curso, necesitamos saber si los datos están en su mayoría concentrados alrededor de la media o si están dispersos.

6.1. Varianza

La varianza es en esencia el promedio del cuadrado de las distribuciones entre cada observación y la media del conjunto de observaciones. La varianza se denota por:

$$s^2 = \sum_{i=1}^{n} \frac{(x_i - \bar{x})^2 . f_i}{n-1}$$

Ejemplo: *Calcular la varianza respecto de la media para cada uno de los cursos*

$$s_A{}^2 = \sum_{i=1}^{n} \frac{(x_i - \bar{x})^2 . f_i}{n-1} = \frac{(1-6)^2.1 + (2-6)^2.2 + (3-6)^2.2 + (4-6)^2.1 +}{25-1}$$

$$= \frac{(5-6)^2.2 + (6-6)^2.7 + (7-6)^2.3 + (8-6)^2.3 + (9-6)^2.2 + (10-6)^2.2}{25-1} = 6{,}08$$

$$s_B{}^2 = \sum_{i=1}^{n} \frac{(x_i - \bar{x}\,)^2.f_i}{n-1} = \frac{(1-6)^2.4 + (2-6)^2.1 + (3-6)^2.1 + (4-6)^2.1 +}{25-1}$$

$$= \frac{(5-6)^2.2 + (6-6)^2.6 + (7-6)^2.1 + (8-6)^2.2 + (9-6)^2.2 + (10-6)^2.5}{25-1} = 9{,}92$$

$$s_C{}^2 = \sum_{i=1}^{n} \frac{(x_i - \bar{x}\,)^2.f_i}{n-1} = \frac{(1-6)^2.1 + (2-6)^2.1 + (3-6)^2.1 + (4-6)^2.1 +}{25-1}$$

$$= \frac{(5-6)^2.3 + (6-6)^2.11 + (7-6)^2.1 + (8-6)^2.3 + (9-6)^2.2 + (10-6)^2.1}{25-1} = 4{,}33$$

De este análisis se puede observar que el curso C es el que posee una menor varianza, por lo tanto los datos están en su mayoría concentrados alrededor de la media.

La varianza es una medida razonablemente buena de la variabilidad debido a que si muchas de las diferencias son grandes (o pequeñas) entonces el valor de la s^2 será grande (o pequeño). El valor de la varianza puede sufrir un cambio muy desproporcionado, aún más que la media, por la presencia de algunos valores extremos del conjunto.

6.2. Desviación estándar

La raíz cuadrada positiva de la varianza recibe el nombre de desviación estándar y se denota por:

$$s = \sqrt{\sum_{i=1}^{n} \frac{(x_i - \bar{x}\,)^2.f_i}{n-1}}$$

Representa la desviación promedio de los valores de la muestra respecto de la media aritmética, indica cuanto se alejen respecto de la media en promedio los valores de la muestra.

Ejemplo: *Calcular la desviación estándar respecto de la media para cada uno de los cursos*

$S_A = \sqrt{6{,}08} = 2{,}47$ $S_B = \sqrt{9{,}92} = 3{,}15$ $S_C = \sqrt{4{,}33} = 2{,}08$

La interpretación de la desviación estándar en el curso C es: En promedio el cuadrado de los desvíos de las notas respecto de la media aritmética es de 2,08

La varianza y la desviación estándar no son medidas de variabilidad distintas debido a que la última no puede determinarse a menos que se conozca la primera.

A menudo se prefiere la desviación estándar en relación a la varianza, porque se expresa en las mismas unidades físicas de las observaciones.

6.3 Coeficiente de variación

La varianza y la desviación estándar dependen de las unidades de la variable X. Para comparar dispersiones de variables que tengan unidades distintas podemos emplear el llamado Coeficiente de Variación, que se define como

$$CV = \frac{s}{|\bar{x}|}$$

es a dimensional (y sólo definida si $\bar{x} \neq 0$). En general se multiplica por 100 y así expresa un porcentaje.

Ejemplo: Si queremos comparar la dispersión de las variables potencia y velocidad de dos conjuntos de datos cuyas medidas son $\bar{x}$ = 142 s = 5 $\bar{x}$ = 51 s = 5
CV de potencia = 28.4%
CV de velocidad = 10.2%

Interpretación: Los datos de potencia están más dispersos alrededor de su media que los de la velocidad.

7. Medidas de Forma

Comparan la forma que tiene la representación gráfica, bien sea el histograma o el diagrama de barras de la distribución, con la distribución normal.

7.1. Medidas de asimetría

Diremos que una distribución es simétrica cuando su mediana, su moda y su media aritmética coinciden.

Diremos que una distribución es *asimétrica a la derecha* si las frecuencias (absolutas o relativas) descienden más lentamente por la derecha que por la izquierda.

Si las frecuencias descienden más lentamente por la izquierda que por la derecha diremos que la distribución es *asimétrica a la izquierda.*

Existen varias medidas de la asimetría de una distribución de frecuencias. Una de ellas es el

7.1.1. Coeficiente de Asimetría de Pearson:

$$A_s = \frac{\bar{x} - M_o}{s}$$

Su valor es cero cuando la distribución es simétrica, positivo cuando existe asimetría a la derecha y negativo cuando existe asimetría a la izquierda.

